

# TF-IDF

Les deux textes sont dans ~/input  
Il y a 4 jobs MapReduce:

## 1. WordCount

On transforme les majuscules en minuscules puis on retire les caractères spéciaux ()/;\$^... en filtrant avec la regex "[^\\w\\s]"

input -> output1

Calcule le total de chaque mot par texte et écris :

old@callwild.txt -> "3"

## 2. WordCountDoc

output1 -> output2

Calcule le nombre total de mot dans chaque texte :

and@callwild.txt -> "1464;31778"

## 3. DocCountWord

output2 -> output3

Calcule le tf-idfs d'un mot

the@callwild.txt -> 0.07168

## 4. SortKeyByValue

output3 -> output4

Ordonne par ordre décroissant les tf-idfs avec une clef custom dans un job Map. Renvoie

customKey -> the@callwild.txt -> 0.07168481339291334

## Résultat - Top 20

Mot	Texte	Tf-Idf
the	callwild	0.07168
the	robinson	0.04850
and	callwild	0.04178
i	robinson	0.04233
and	robinson	0.03960
to	robinson	0.03543
of	robinson	0.02899
of	callwild	0.02740
he	callwild	0.02555
was	callwild	0.02187
to	callwild	0.02124
a	callwild	0.02064
a	robinson	0.01860

